

数据科学分论坛

云端的数据湖现代化的数据架构

张孝峰 AWS资深解决方案架构师

属于数据时代



下一代客户忠诚度计划 供应链优化 路 货品陈列优化 器

竞品分析

BIG DATA

产品定价规范性分析本地化的产品分类

L 店内行为分析

舆情热点

实时订单追踪



亚马逊与大数据的创新



亚马逊自从成立以来在大数据领域 持续大量投入,目前在人工智能和机器 学习领域已经取得很多的成果。 并且把我们的知识与能力与客户分享



1995 第一代 Personal Notification Service



2017 无人送货飞机













商品智能推荐

机器人与物流仓储

新产品

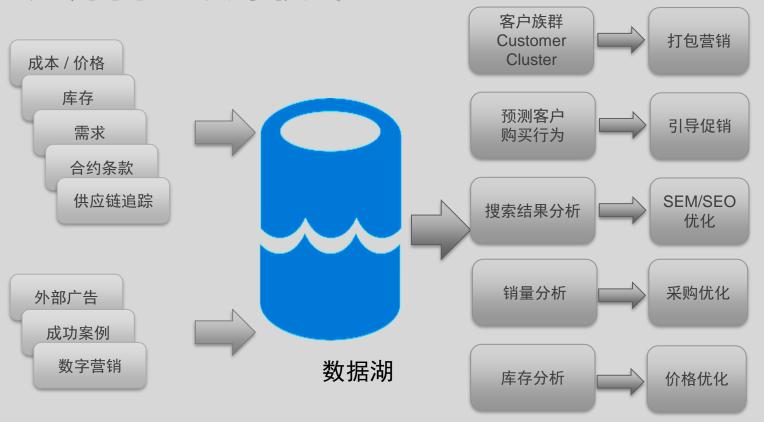
供应链管理

智慧呼叫中心

无人值守商店



新零售下的决策模式



自动化营销

自动化采购



数据湖的优势 - 所有数据在一个地方



"我的数据储存在多个不同的地方,那一份数据才是真实可信的呢?"



在一个集中的位置, 储存并分析来自所有来源的数据



数据湖的优势 - 快速提取



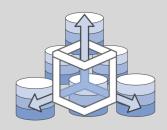
"如何快速从各种来源收集数据并有效存储?"



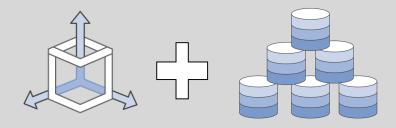
快速提取数据, 而无需将其强制转换到范式中。



数据湖的优势 - 储存与计算分离



"如何扩展容量, 以应付持续增长的数据?"



将存储和计算分开, 可以根据需要缩放每个组件。



数据湖的优势 - 读取时范式化



"有没有办法将多个分析和处理框架应 用于相同的数据?"



数据湖可以通过在读取时范式化来进行即时分析,而不是在写入时。



数据三重门

公开市场门 - 外部数据 -<u>ि व</u> **#**

交互门

- 企业数据采集前移 -



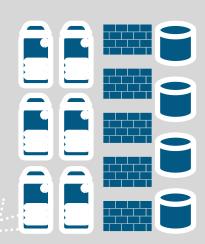






外场数据

交易门



服务器 数仓和BI 存储



扩大使用者的范围

数据科学家









- 1.更多的角色需要通过适当的工具访问数据
- 2.更多的系统需要链接到数据进行决策和过程自动化
- 3.用户需要能够查找信息并安全地访问它



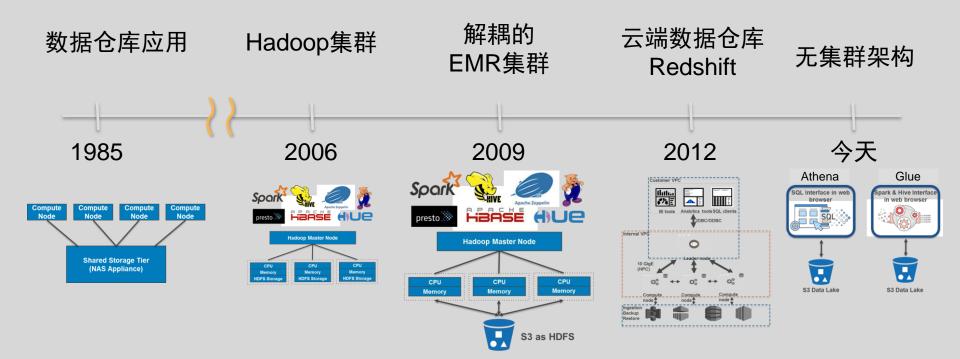
业务数据呈指数级增长

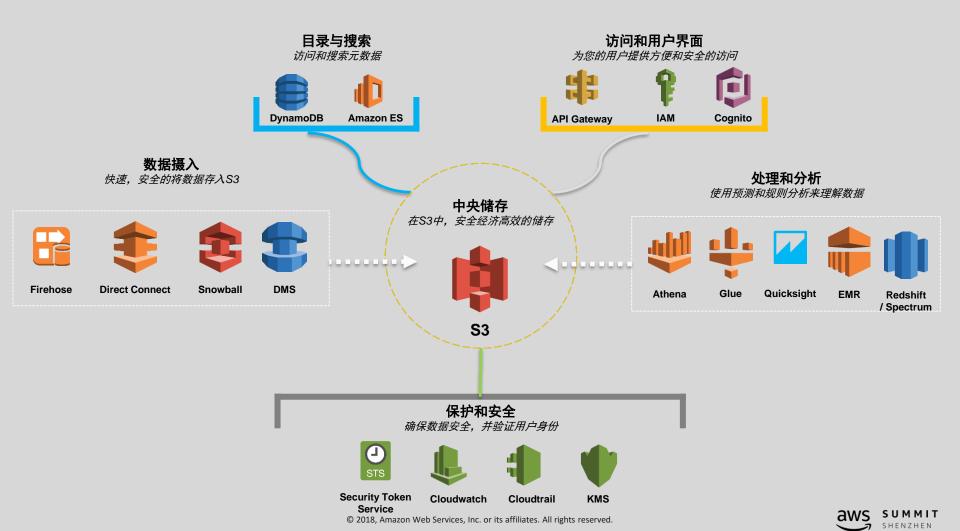


- 1. 数据来自不同的来源,他们有不同的速度和规模
- 2. 需要把数据放在一起,打破传统的数据孤岛
- 3. 产生价值需要超过收集和分析的成本



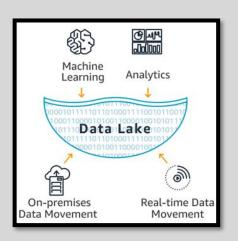
数据分析平台技术的演变





为什么Amazon S3是云端数据湖的核心

数据湖是非常适合部署在云中的工作负载, 因为云提供高性能、可扩展性、可靠性、 可用性、多种分析引擎以及规模经济带来 的成本收益





高持久性

高达11个9的 数据持久性



高可用性

99.99% 数据可用性



高性能

并行吞吐 范围获取



易于使用

- 标准REST API
- AWS SDKs
- 写后读一致性
- 生命周期管理



无限扩容

- 按需储存,无需预估容量
- 储存与计算分离
- 无需承诺最小使用量



开放扩展

- · 最受合作伙伴、供应商和 AWS 产品支持
- Talend / Apache Camel
- Apache Nifi /Apahce



S3可以多快



使用Amazon Athena扫描数据——无需管理集群

```
SELECT date,
    order id,
    order type,
    region,
    cast(sum(order price) AS DECIMAL(19,
    6)) AS price
FROM "order"
LEFT JOIN "user"
  ON uid=userid
WHERE order type in(9, 13, 64, 58)
    AND year='2018'
    AND month='10'
GROUP BY date, order type, order id, region
ORDER BY date DESC limit 100
```

- order表 一千亿条 csv gzip 2T
- user表 五千万条 csv gzip 1.5G

使用AWS Glue自动建立分区

查询时长 8.47秒 数据扫描量 10.19GB 成本 \$0.05



S3可以作为大数据的热储存



高吞吐(优于传统HDFS)



安全可控





S3可以多省



存放在HDFS

1PB数据

存放在S3



复制因子 = 3 3 PB



磁盘预留空间 25% 4 PB

单价 ST1: \$0.045 / 每月GB

总价 \$ 188,743.68 / 月



1 PB (按实际使用计算)

单价 S3: 约 \$0.02155 / 每月GB

> 总价 \$ 22,067.2 / 月

价格以美国东部(弗吉尼亚北部)为例 https://aws.amazon.com/s3/pricing/
© 2018, Amazon Web Services, Inc. or its affiliates. All rights reserved.



你可以省更多







标准低频率访问 S3-IA 存储



Glacier 存储

更便宜!



减轻运维



计算能力与储存解耦

计算能力









储存能力

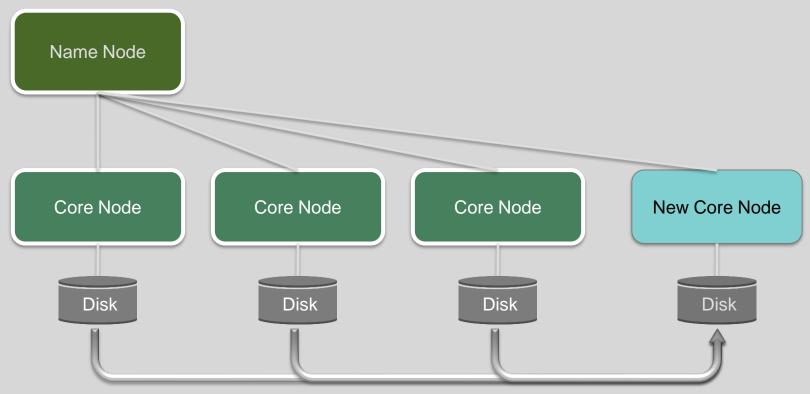








Hadoop HDFS数据的重平衡



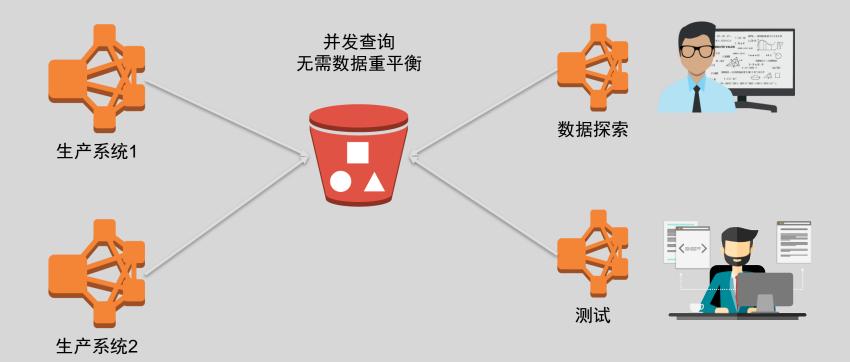
数据重平衡



灵活创新



S3支持多个EMR集群同时查询同一批数据



Netflix 选用S3作为 "Source of Truth"



- S3 的11个9的可靠性和4个9的可用性, 可以承受在两个物理设施发生故障
- S3支持存储桶的版本控制,可以防止 意外数据丢失(比如开发人员误删除)
- 弹性。S3提供了无上限的存储空间。 从几百个TB到PB的成长过程中无需预 先配置任何存储资源
- 使用S3作为数据存储使我们能够运行 适应故障和负载的多个高度动态的集 群。



Netflix使用S3作为可扩展的数据架构

ETL, SLA, 生产

额外集群 2200+ m1.xlarge 3 x 150 m2.4xlarge





即时查询,探索,测试

2000+ m1.xlarge



250 m2.4xlarge

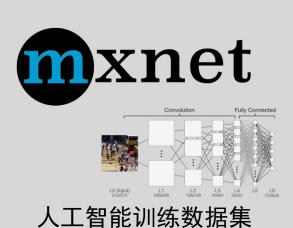








更多的大数据可以使用S3

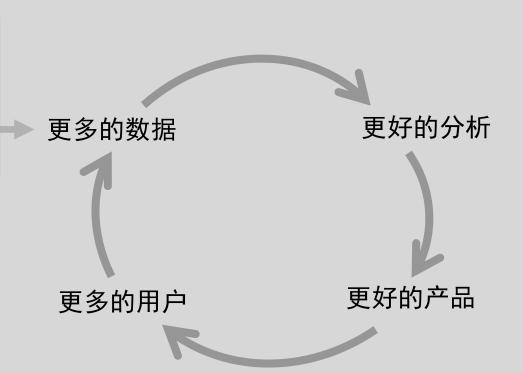






围绕数据的"飞轮"

点击流 用户活动 内容生成 购买 点击 喜好 传感器数据

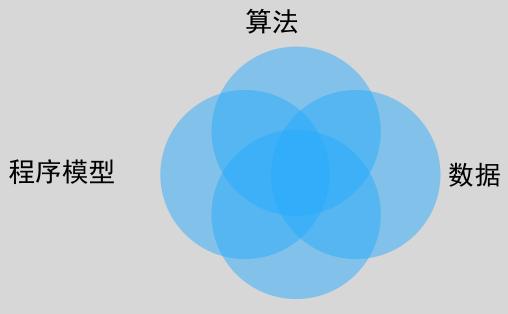


对象存储 数据库 数据仓库 数据流分析 商业智能 Map/Reduce 内存数据库 数据检索

机器学习 深度学习 人工智能



AI就是大数据时代的革命

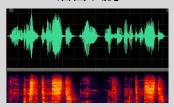


GPUs & 计算加速

图像理解



语音识别



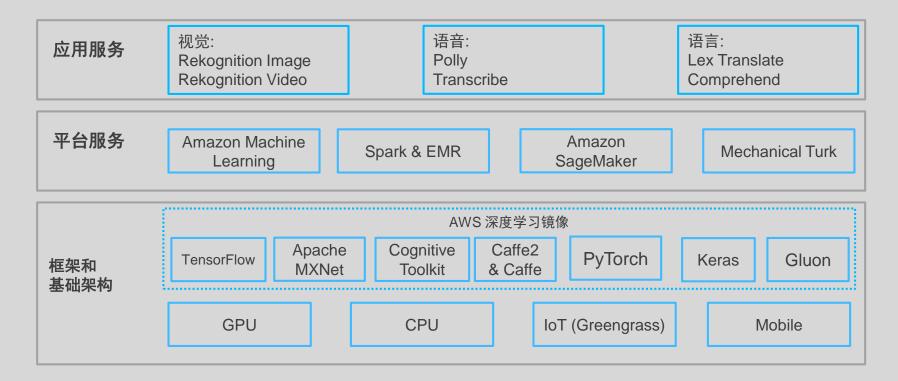
自然语言处理



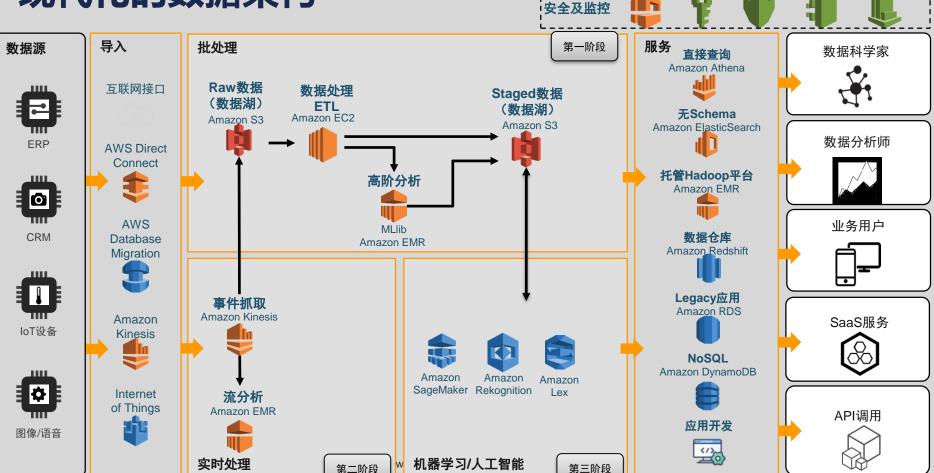
机器自主



AWS上的机器学习技术堆栈



现代化的数据架构



AWS

IAM

Amazon

VPC

平台

AWS

KMS

AWS

Amazon

Cloud Trail CloudWatch

AWS完整的云端数据湖方案





吸纳新的数据类型,构建差异化的体验:

图片/视频, 社交媒体, IoT 传感器 及更多数据



单一数据源 ("data lake")

适合于任何数据和任何分析 高度安全,极度弹性 **再无数据孤岛**



面向各种任务类型的 分析平台

具备最新的分析能力 机器学习,自然语言处理,托 管Hadoop服务等





谢谢大家

扫码下载演讲资料

